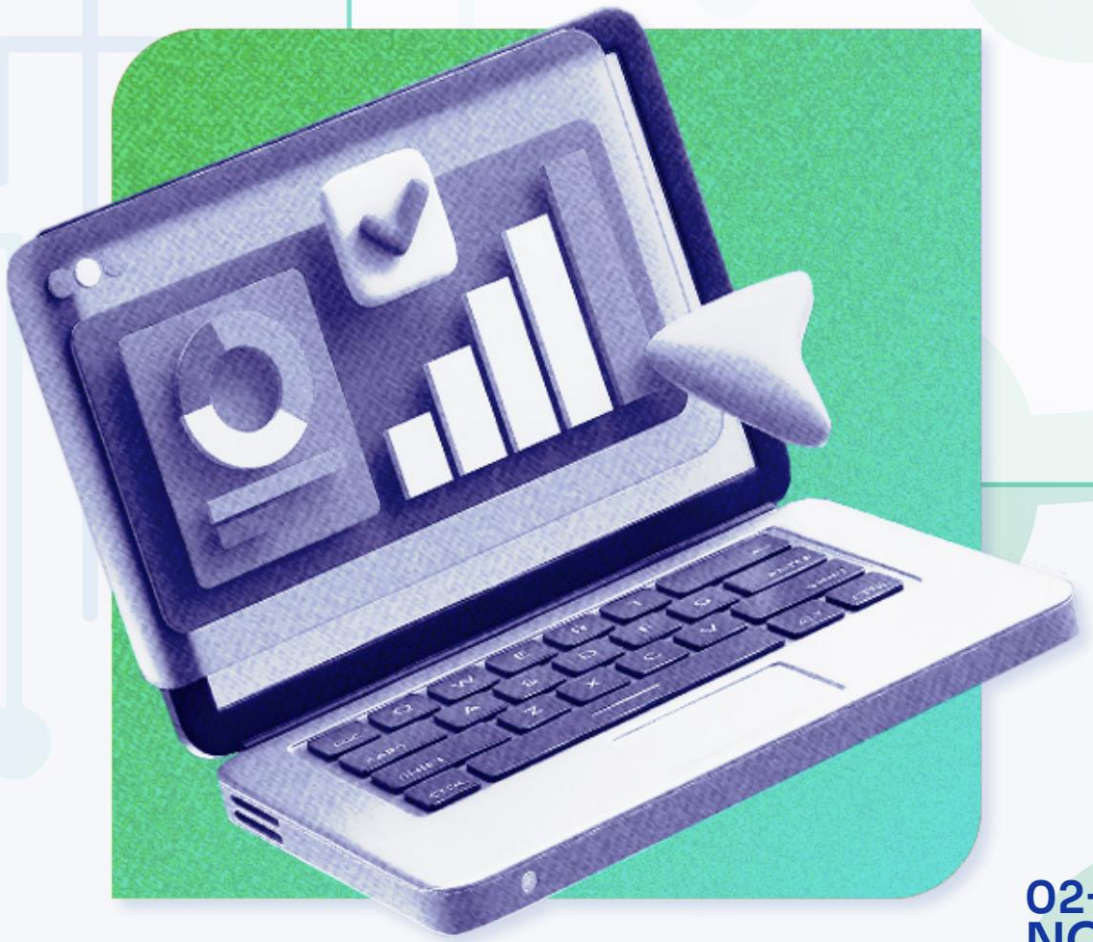
50 YEARS: Tecnológico de Monterrey | Campus Chihuahua • Guest Country of Honor: FRANCE | 200 Years of France–Mexico Friendship

MICAI 25 EDITION 2000-2026

Datathon



CON EL APOYO DE:

databricks

Institute for the Future of Education Tecnológico de Monterrey | Data Hub

Empresas participantes:

EMERSON

GCC

GRUPO ROGA

02-06 NOV 2026 MEXICAN INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE |ITESM Campus Chihuahua

25TH EDITION OF MICAI: Mexican International Conference on Artificial Intelligence | 02 - 06 November 2026 | Chihuahua, Mexico

Agenda (120 min)

0:00 – 0:10	Bienvenida, dinámica del datathon y reglas
0:10 – 0:25	Databricks Free Edition: plataforma, límites y navegación
0:25 – 0:45	Unity Catalog: catálogo, esquema, volumen y tablas. Carga de datos
0:45 – 1:00	Notebooks, SQL, arquitectura medallón y Genie Code
1:00 – 1:20	Machine Learning con MLflow: tracking, registro, split temporal
1:20 – 1:40	GenAI: parsing de PDFs, chunking, Vector Search y agentes
1:40 – 1:50	Dashboards, producción y portabilidad entre cuentas
1:50 – 2:00	Presentación de los 3 retos, entregables y Q&A

Programa del evento

Lunes 2 de noviembre

- 11:00 a.m. – 2:00 p.m. Inicio del Datathon después de la conferencia magistral y primera sesión de trabajo
  - Descripción de retos, premios y formación de grupos
  - Te ayudamos a integrarte a un equipo si no te registras con uno
  - Entrenamiento de Databricks
- 2:00 – 4:00 p.m. Receso para la comida
- 5:00 – 6:00 p.m. Sesión de dudas, revisión de avances y apoyo a los equipos

Martes 3 de noviembre

- 9:00 a.m. – 12:00 p.m. Primera sesión de trabajo
- 12:00 – 3:00 p.m. Pausa para conferencia magistral y comida
- 3:00 – 7:00 p.m. Segunda y última sesión de trabajo, revisión de avances y cierre de actividades presenciales
- 11:59 p.m. Cierre de la entrega de resultados

Miércoles: Evaluación de proyectos. **Anuncio de ganadores a la 3:00 p.m. Lugar por definir**

Qué te llevas de esta sesión

Plataforma

- Crear y organizar datos en Unity Catalog
- Subir archivos a un volumen
- Usar notebooks y SQL con serverless

Datos e IA

- Pipeline Bronze → Silver → Gold
- Entrenar y registrar modelos con MLflow
- Parsear PDFs, chunking e índice vectorial
- Construir un agente

Ejecución

- Usar Genie Code como copiloto
- Trabajar con límites de consumo
- Mover el trabajo entre cuentas
- Entregar algo reproducible

Dinámica del datathon

- Equipos multidisciplinarios: cada equipo elige o tiene asignado un reto
- Cada reto tiene una carpeta en el repositorio:
  - README.md con el reto, datos, rúbrica y tips
  - datos/ con los insumos crudos
- Stack libre, pero se recomienda Databricks Free Edition
- La solución debe correr de punta a punta sin intervención manual
- Evaluación con la rúbrica oficial de cada empresa
- Demo grabada en la carpeta

Reglas clave

- Los datos entregados son la fuente principal
- Documentar decisiones
- Reproducibilidad = puntos
- Sin data leakage en modelos

Databricks Free Edition

- Registro gratuito con correo personal
- Cómputo serverless: no hay clusters que configurar
- Incluye notebooks, SQL, Unity Catalog, MLflow, dashboards, Genie y funciones de IA
- Tiene límites de consumo diario y de recursos
- Si se alcanza la cuota, el cómputo se pausa hasta el día siguiente

Los límites son parte del reto

- Simulan budgets y cuotas de un entorno empresarial
- Diseñen pensando en costo: consultas acotadas, muestras, cachés
- Cada integrante usa su propia cuenta
- Si una cuenta se queda sin cuota, muevan código y objetos a la cuenta de otro integrante

Democratize Data + AI



Data democratized through AI

AI democratized through your data



Fundada en 2013

DELTA LAKE

mlflow

APACHE Spark

Unity Catalog

DBRX

20,000+
global customers
70% of Fortune 500

>$7B
in annual revenue
80% Growth YoY

$5B+
in investment

Inventor of the **lakehouse**
&
Pioneer of **generative AI**



databricks

The data and AI company

Gartner-recognized Leader
Database Management Systems
Data Science and Machine Learning Platforms

Forrester Wave Leader
Data Lakehouses
AI Foundational Models for Language

Creator of





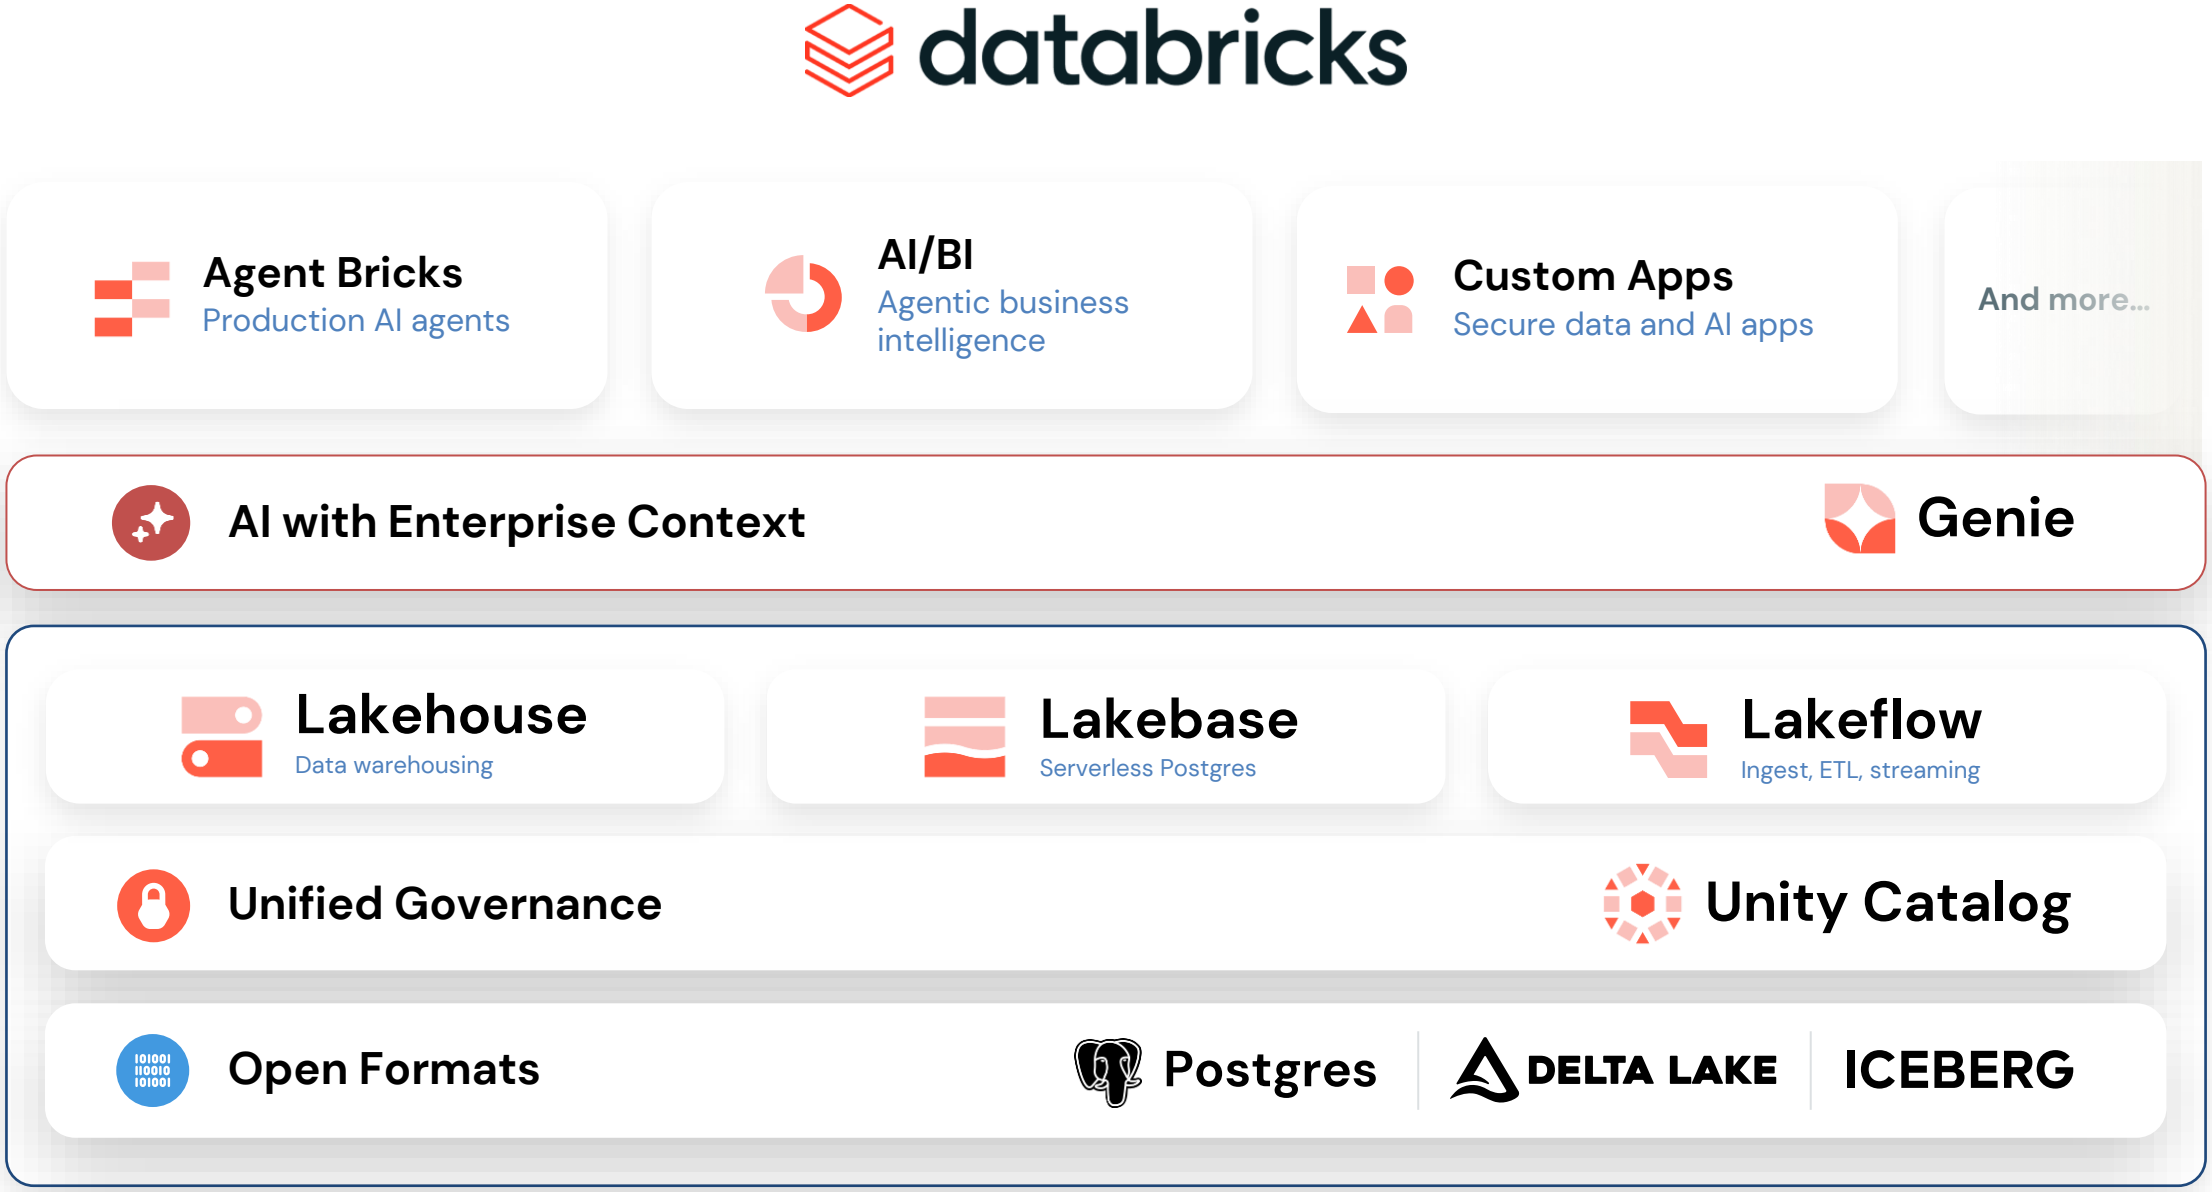






Mosaic MPT




databricks
Agent Bricks
Production AI agents
AI/BI
Agentic business intelligence
Custom Apps
Secure data and AI apps
And more...
AI with Enterprise Context
Genie
Lakehouse
Data warehousing
Lakebase
Serverless Postgres
Lakeflow
Ingest, ETL, streaming
Unified Governance
Unity Catalog
Open Formats
Postgres
DELTA LAKE
ICEBERG

Mapa de la plataforma

Workspace

- Carpetas, notebooks, archivos, Git folders

Catalog

- Unity Catalog: catálogos, esquemas, tablas, volúmenes, modelos

SQL Editor

- Consultas SQL sobre tablas y archivos

Notebooks

- Python + SQL, serverless, visualizaciones

Jobs & Pipelines

- Orquestación y automatización

Experiments

- MLflow: runs, métricas, artefactos

Dashboards

- AI/BI dashboards interactivos

Genie / Genie Code

- Preguntas en lenguaje natural y asistente de código

El Data Lakehouse

Una base abierta y unificada para todos sus datos



Open Data Lake

Todos los datos sin procesar
(Registros, Textos, Audio, Video, Imágenes)

2020

Databricks pionero en la arquitectura lakehouse

Hoy

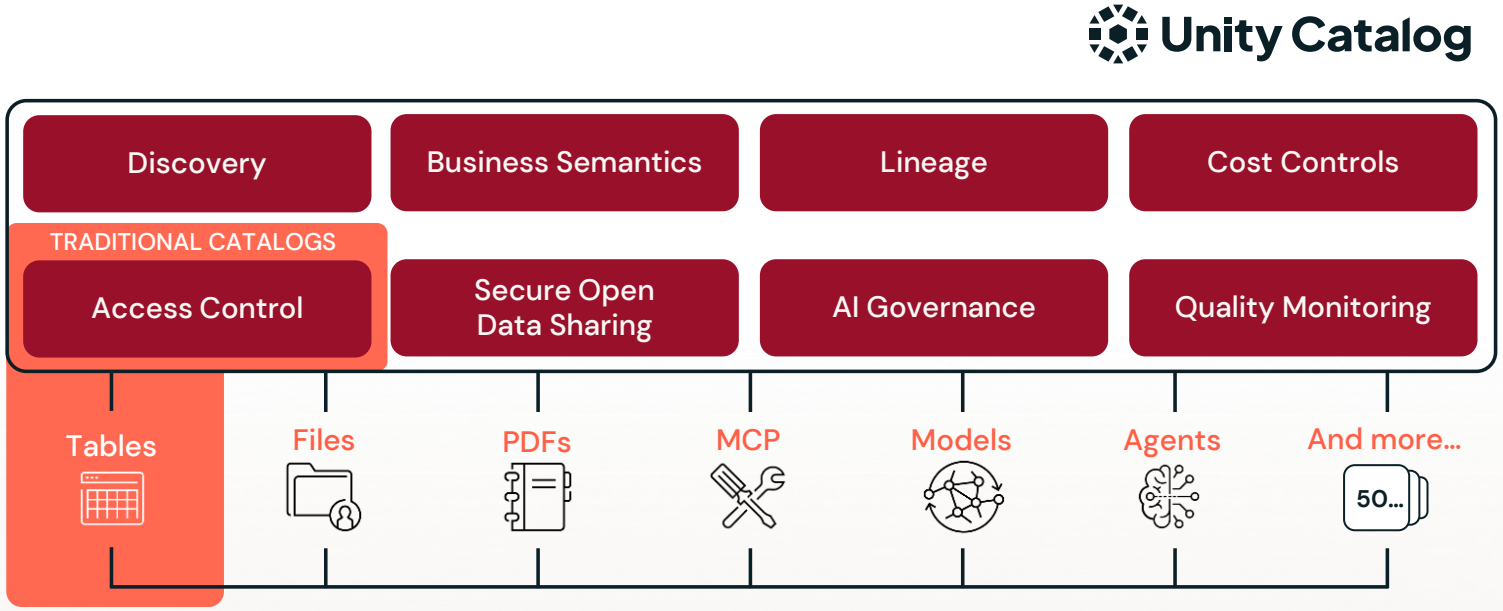
El 74% de las empresas globales han adoptado Lakehouse

Perspectivas de MIT Technology Review, 2023

Unified Governance

Unified capabilities for every use case

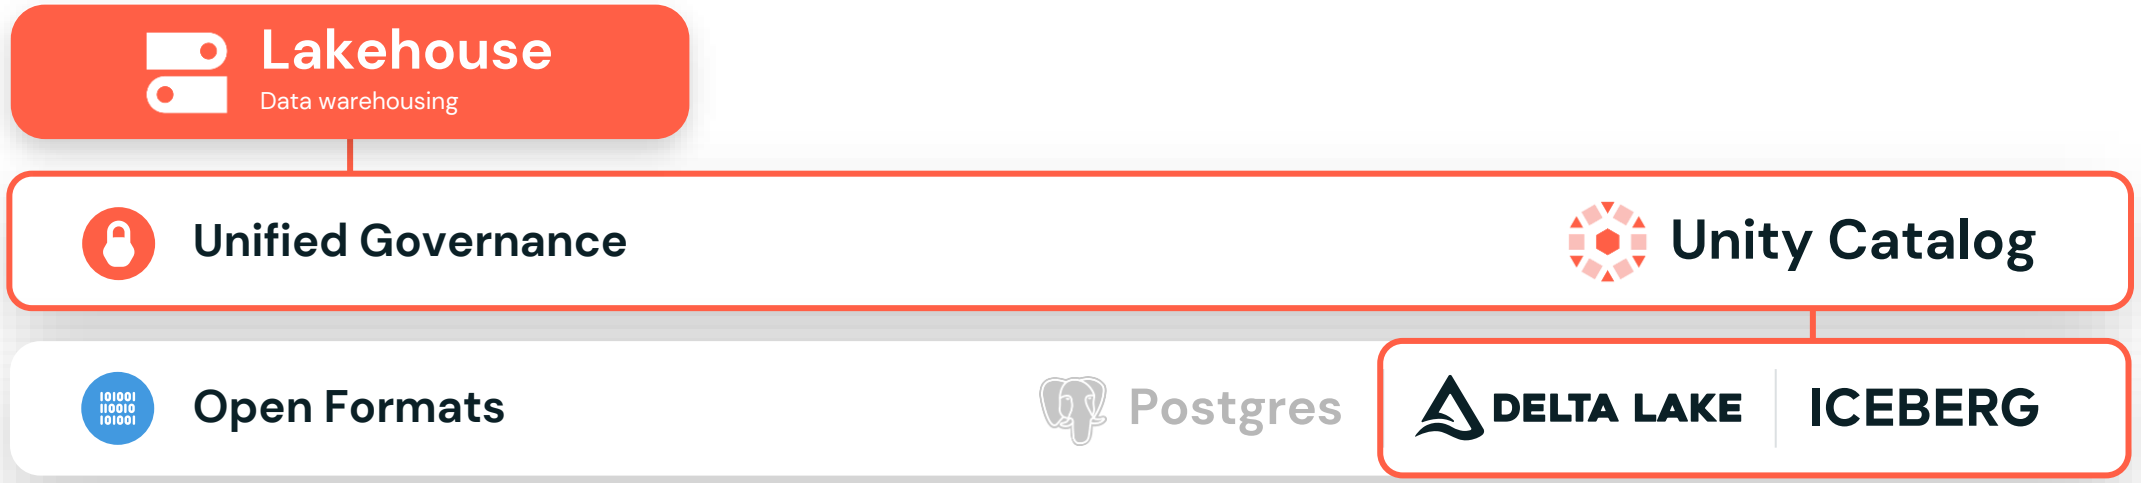
Unified governance for all assets



Unified Governance — Unity Catalog

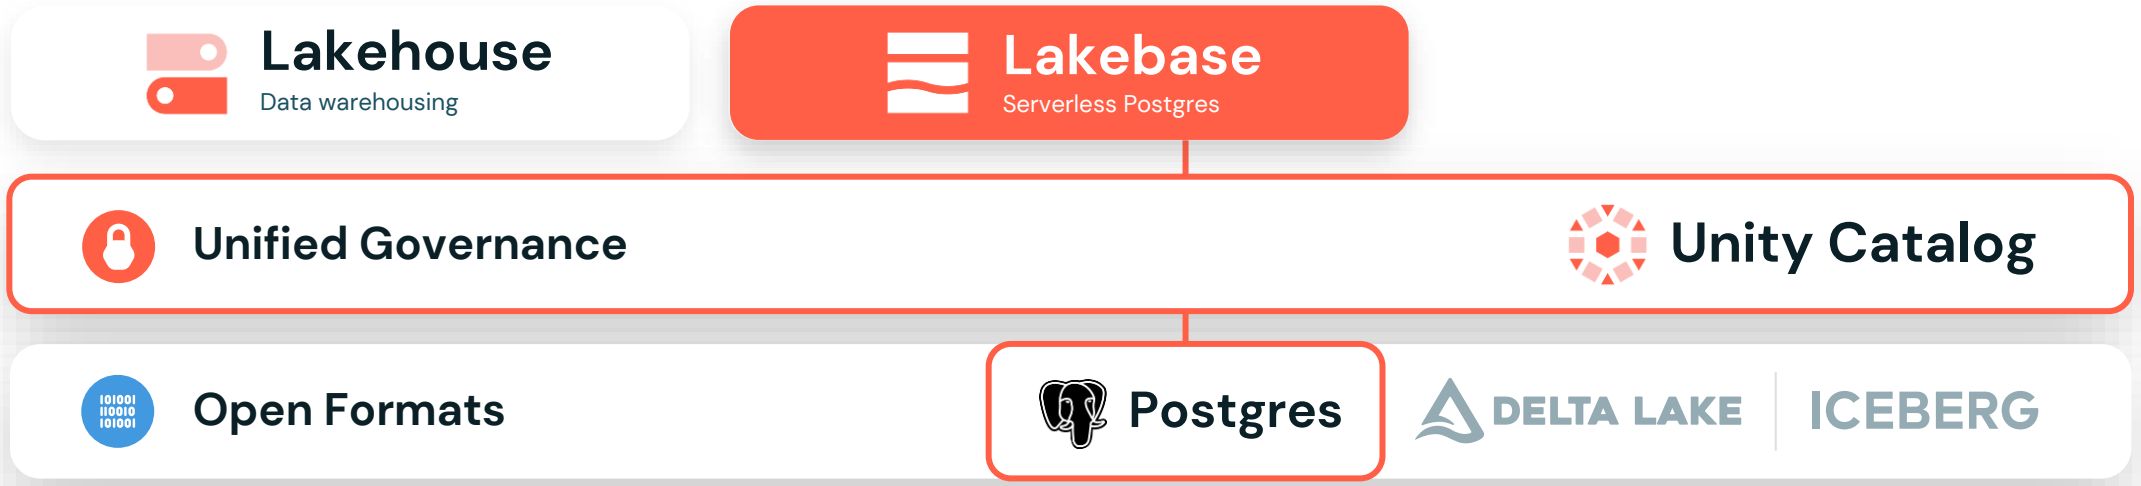
Open Formats — Postgres | DELTA LAKE | ICEBERG

Apply serverless compute



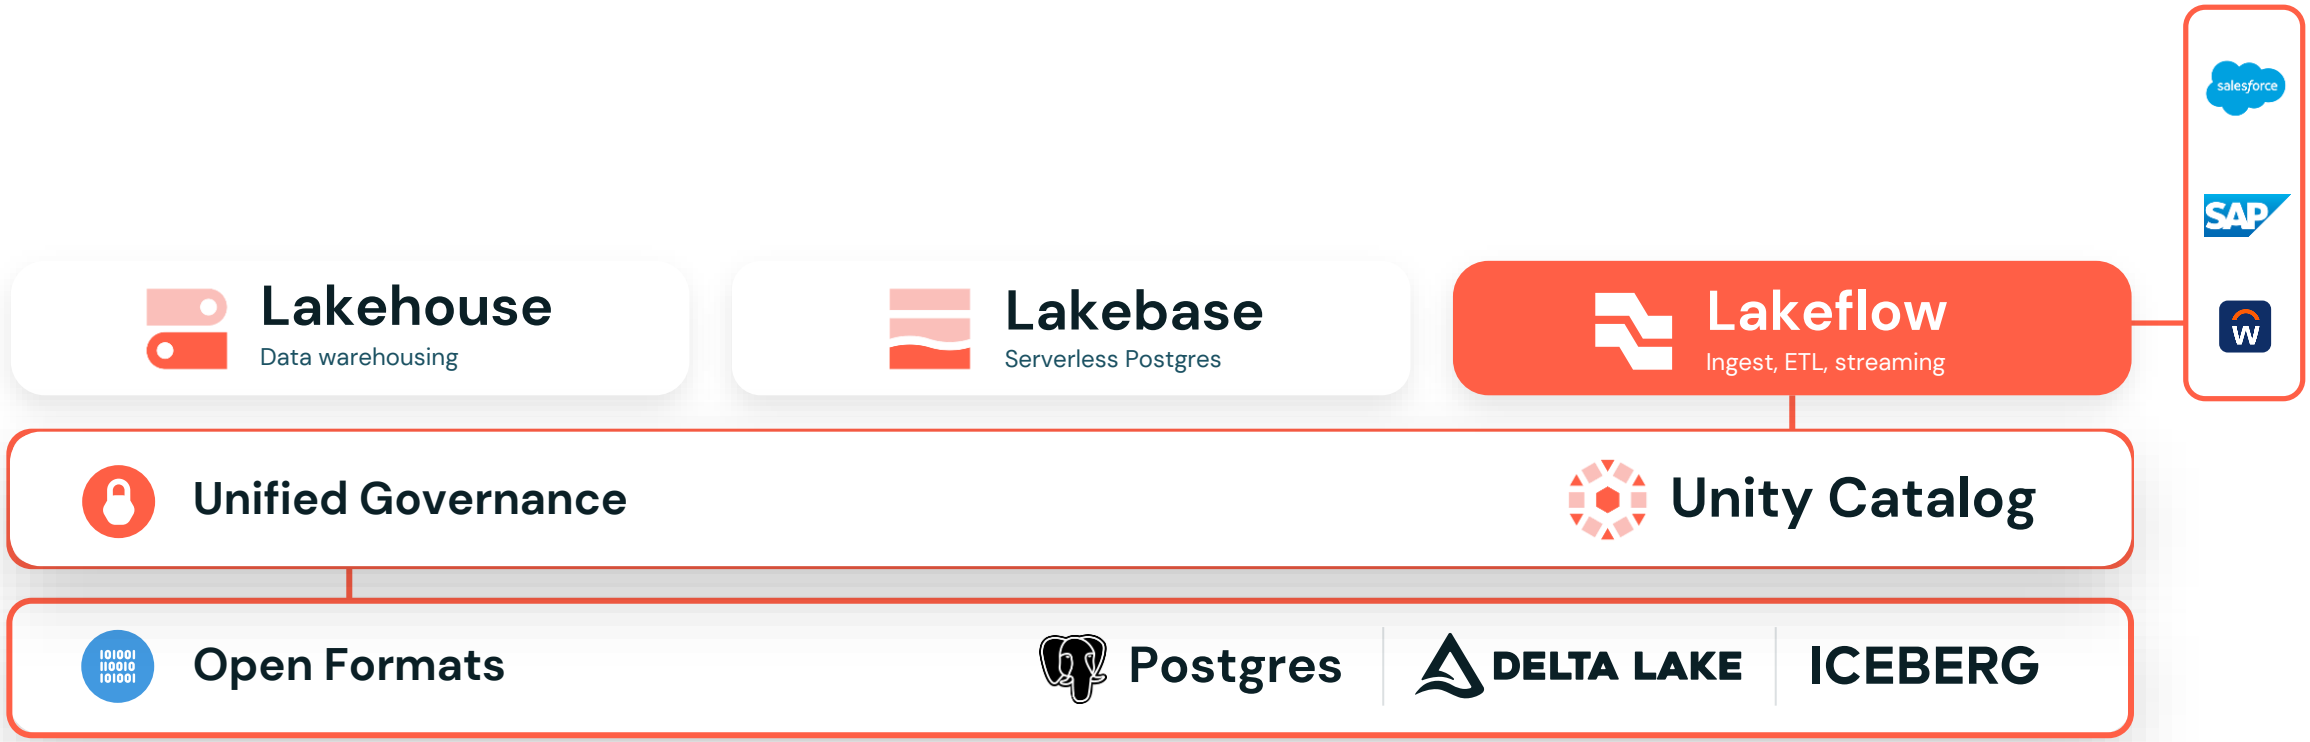
© Databricks 2025. Todos los derechos reservados. Apache, Apache Spark, Spark, el logotipo Spark, Apache Iceberg, Iceberg y el logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

Apply serverless compute



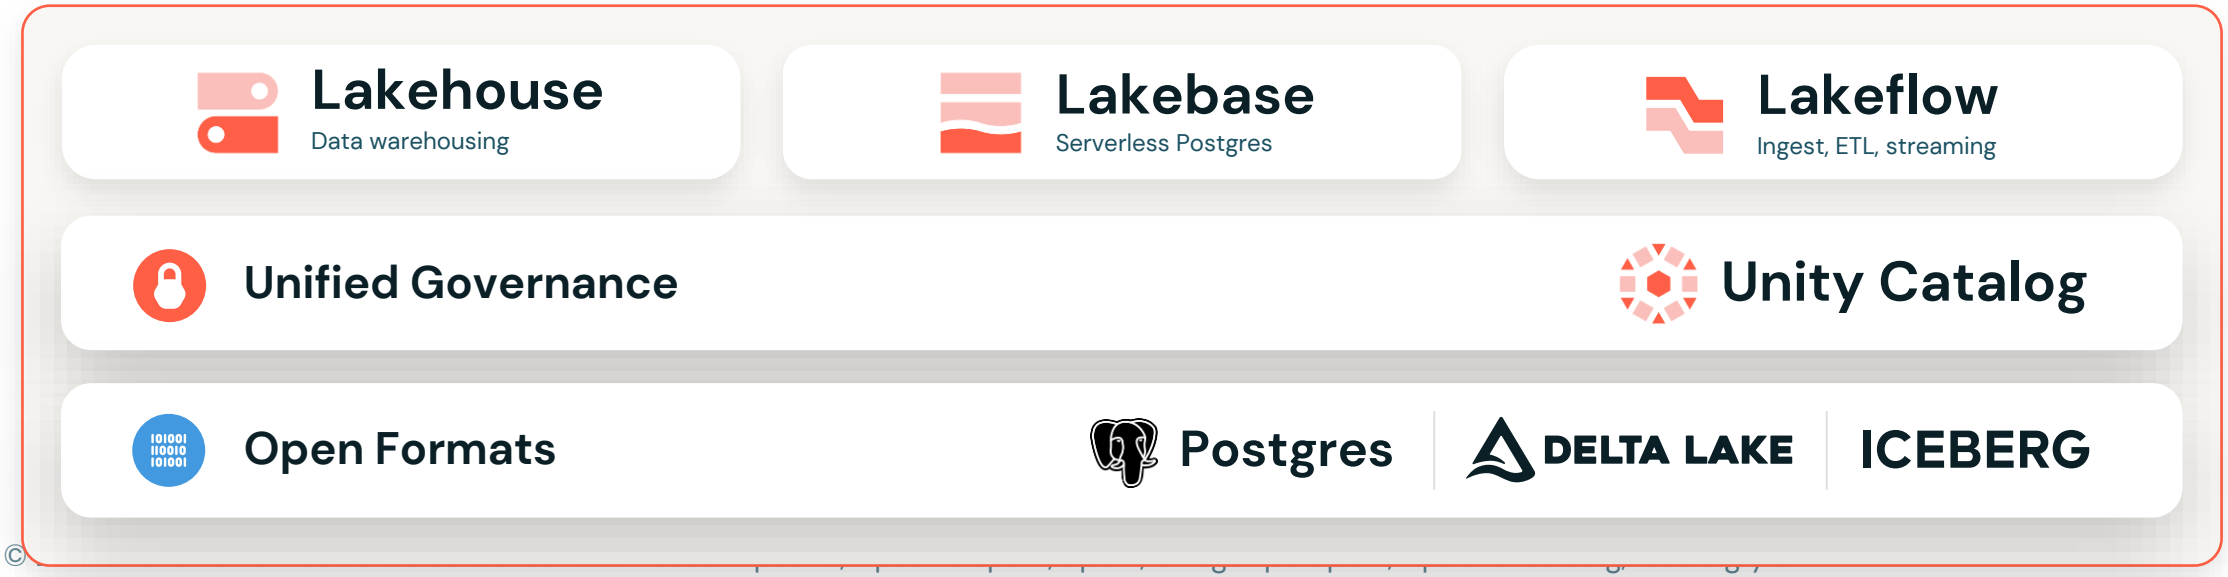
© Databricks 2025. Todos los derechos reservados. Apache, Apache Spark, Spark, el logotipo Spark, Apache Iceberg, Iceberg y el logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

Apply serverless compute



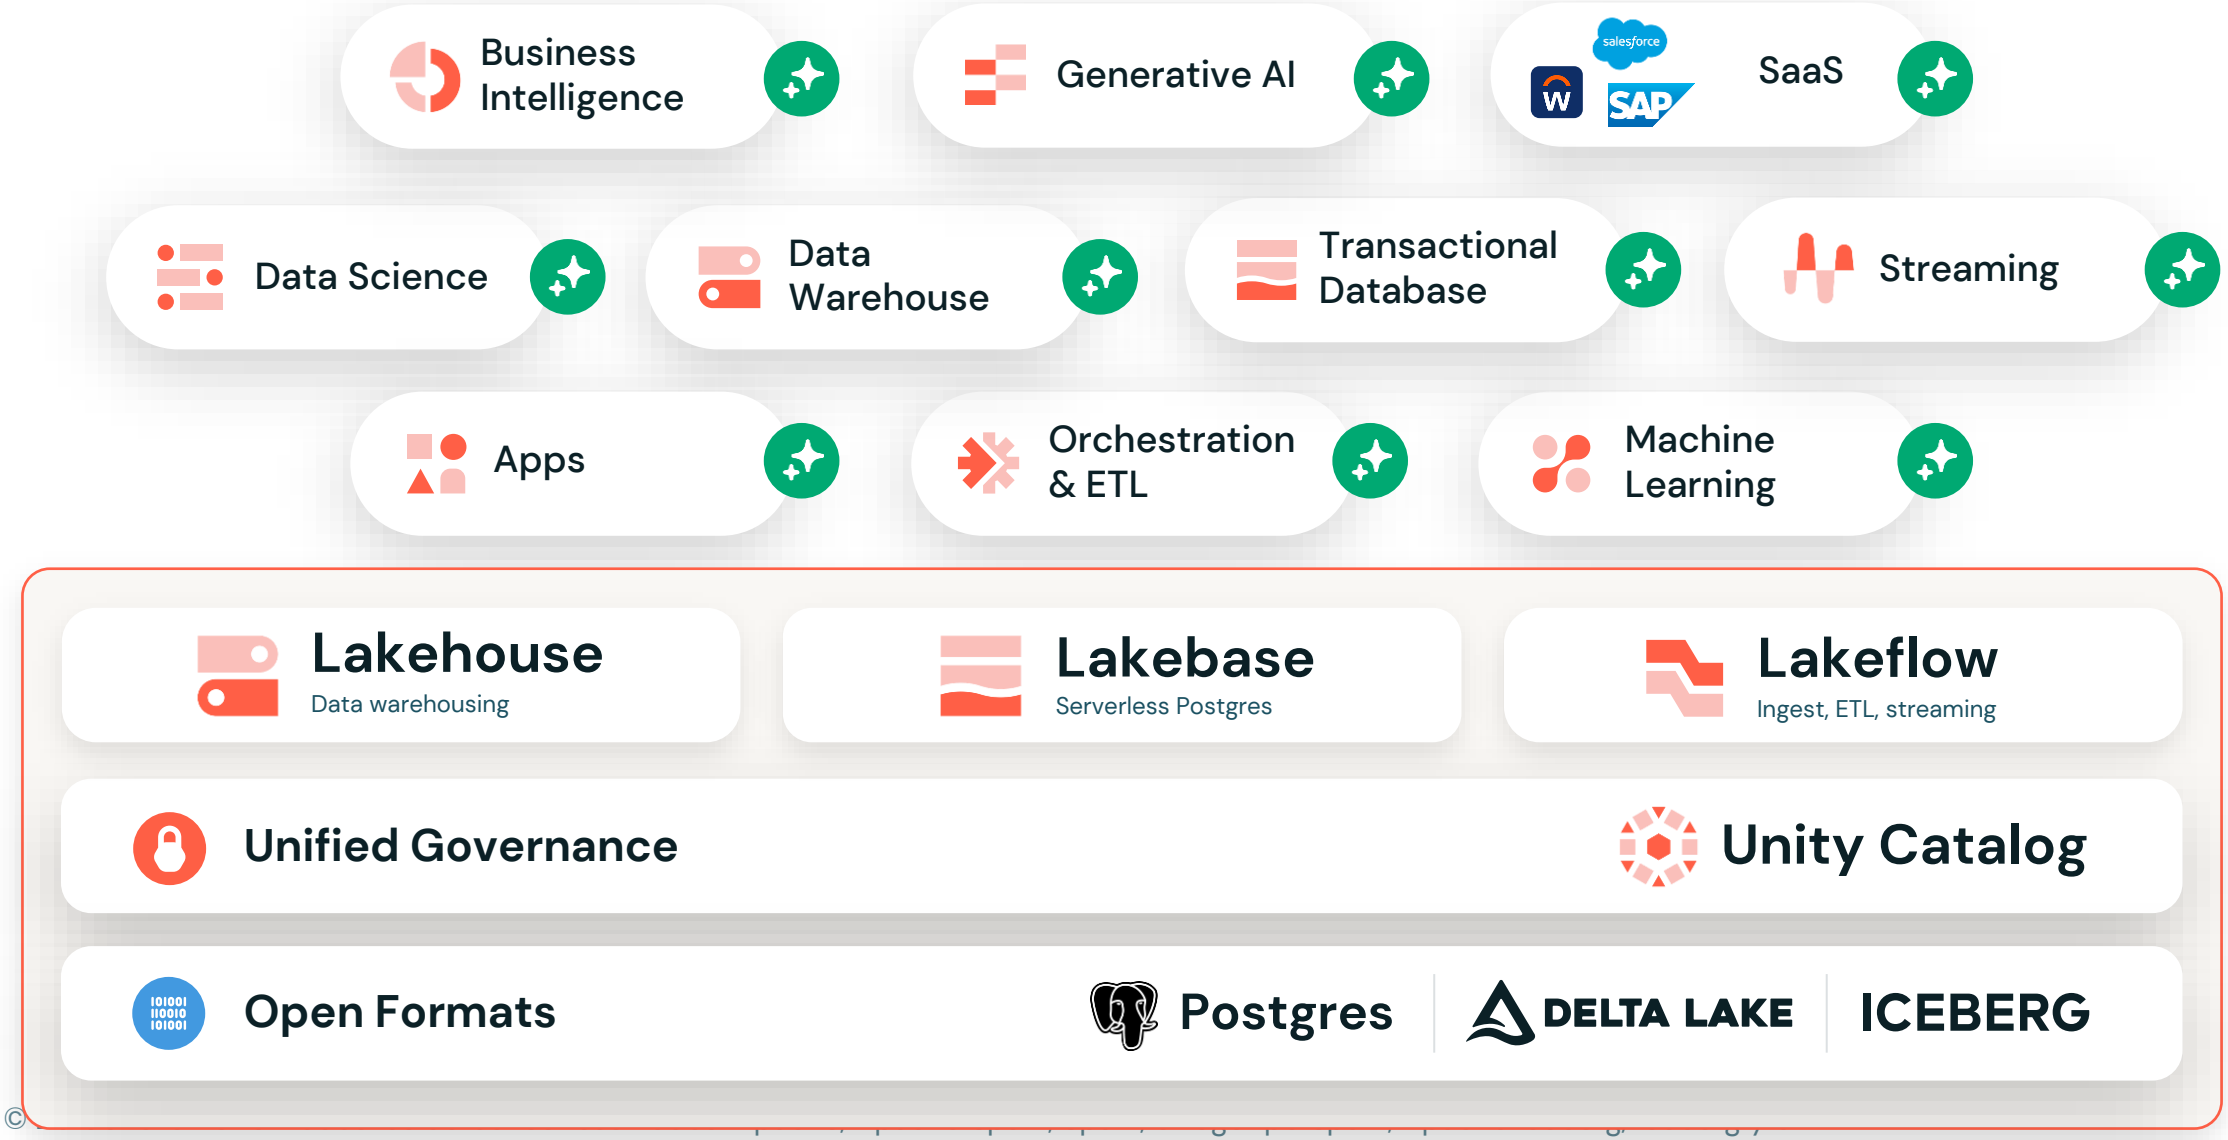
© Databricks 2025. Todos los derechos reservados. Apache, Apache Spark, Spark, el logotipo Spark, Apache Iceberg, Iceberg y el logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

This is the core data platform



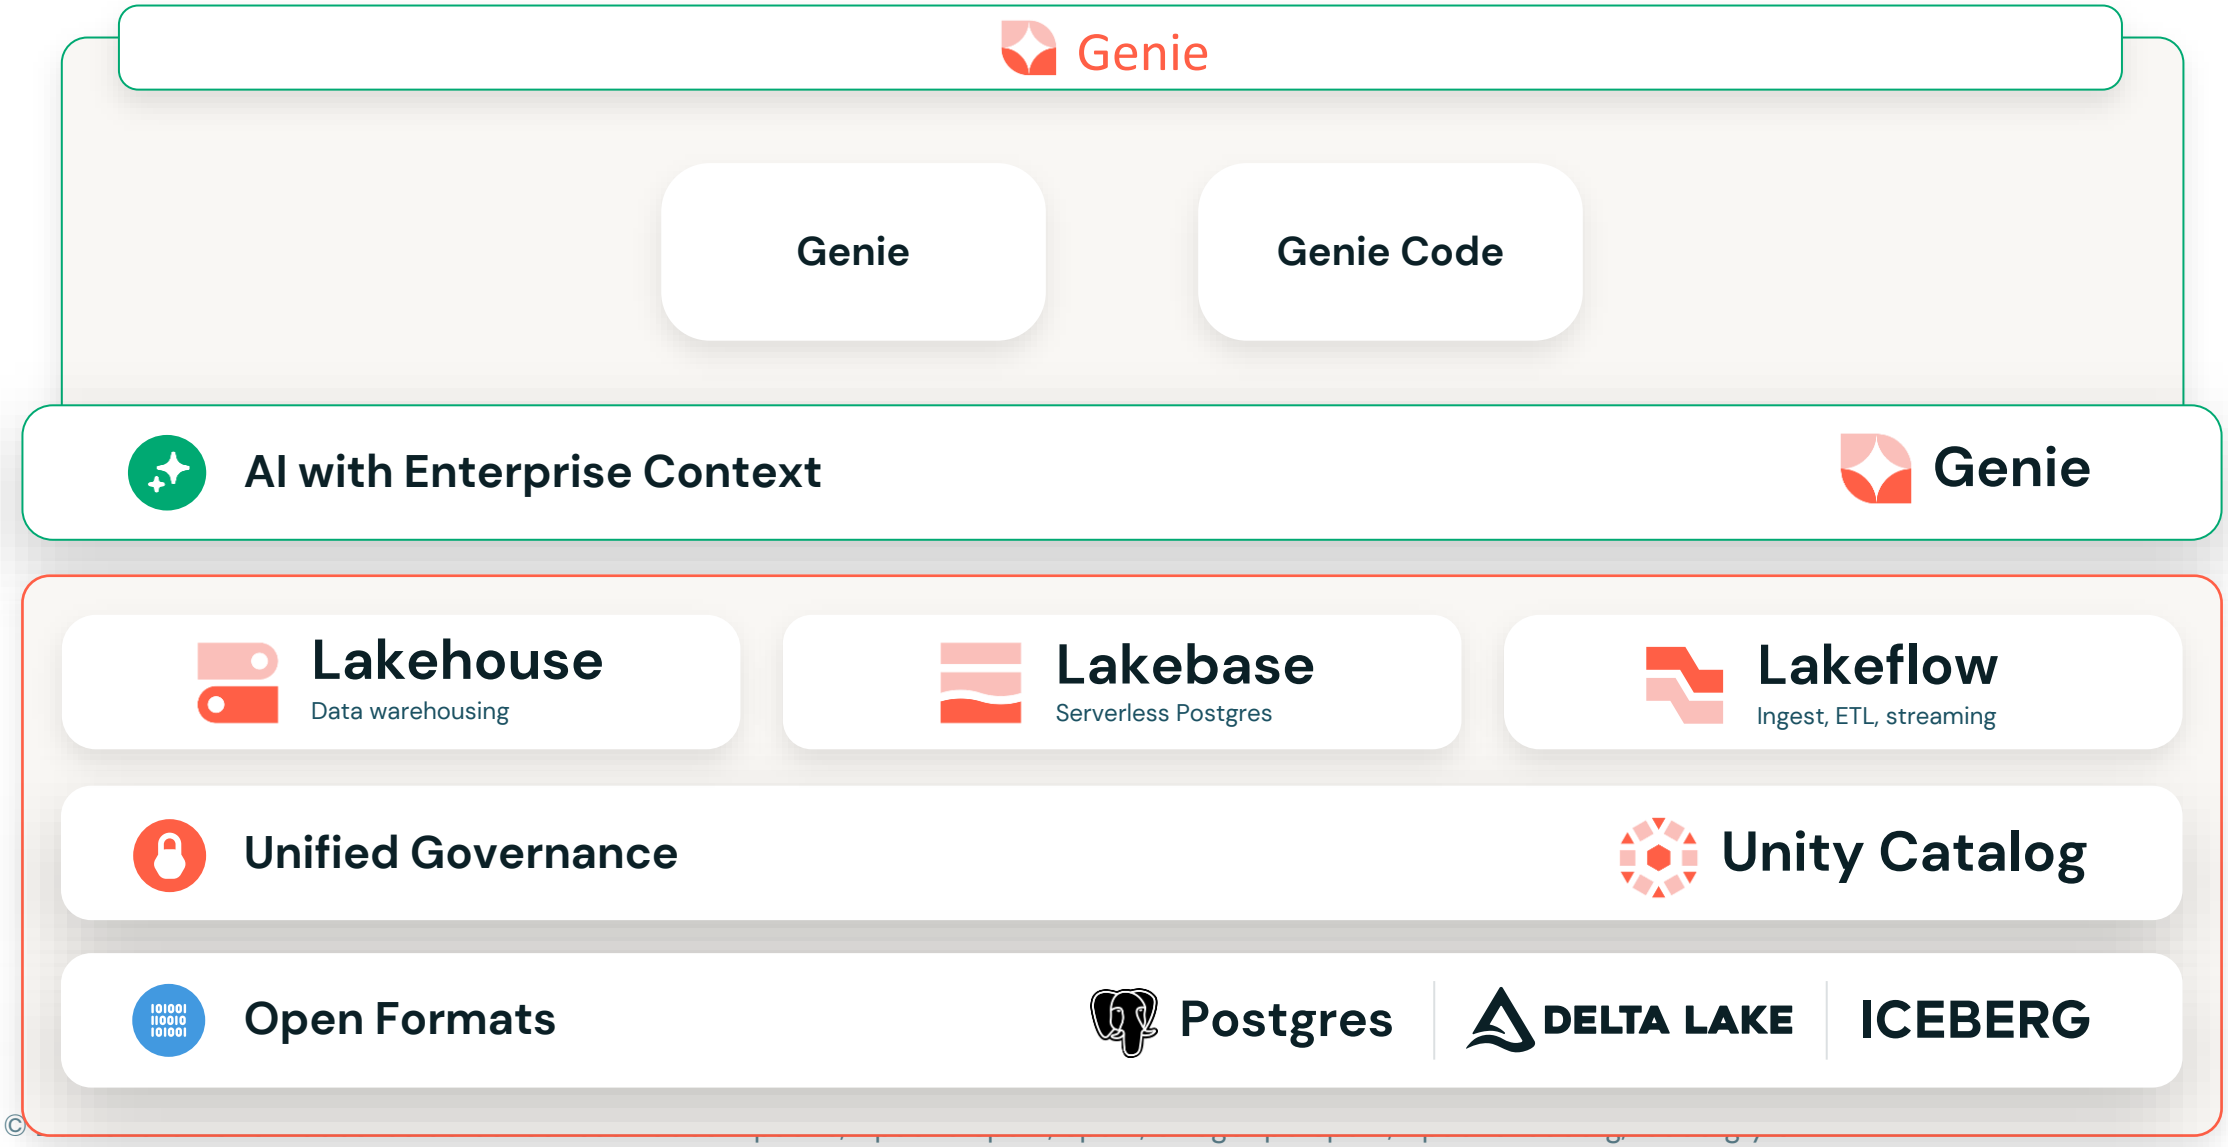
© [illegible] logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

Now deliver enterprise context to AI



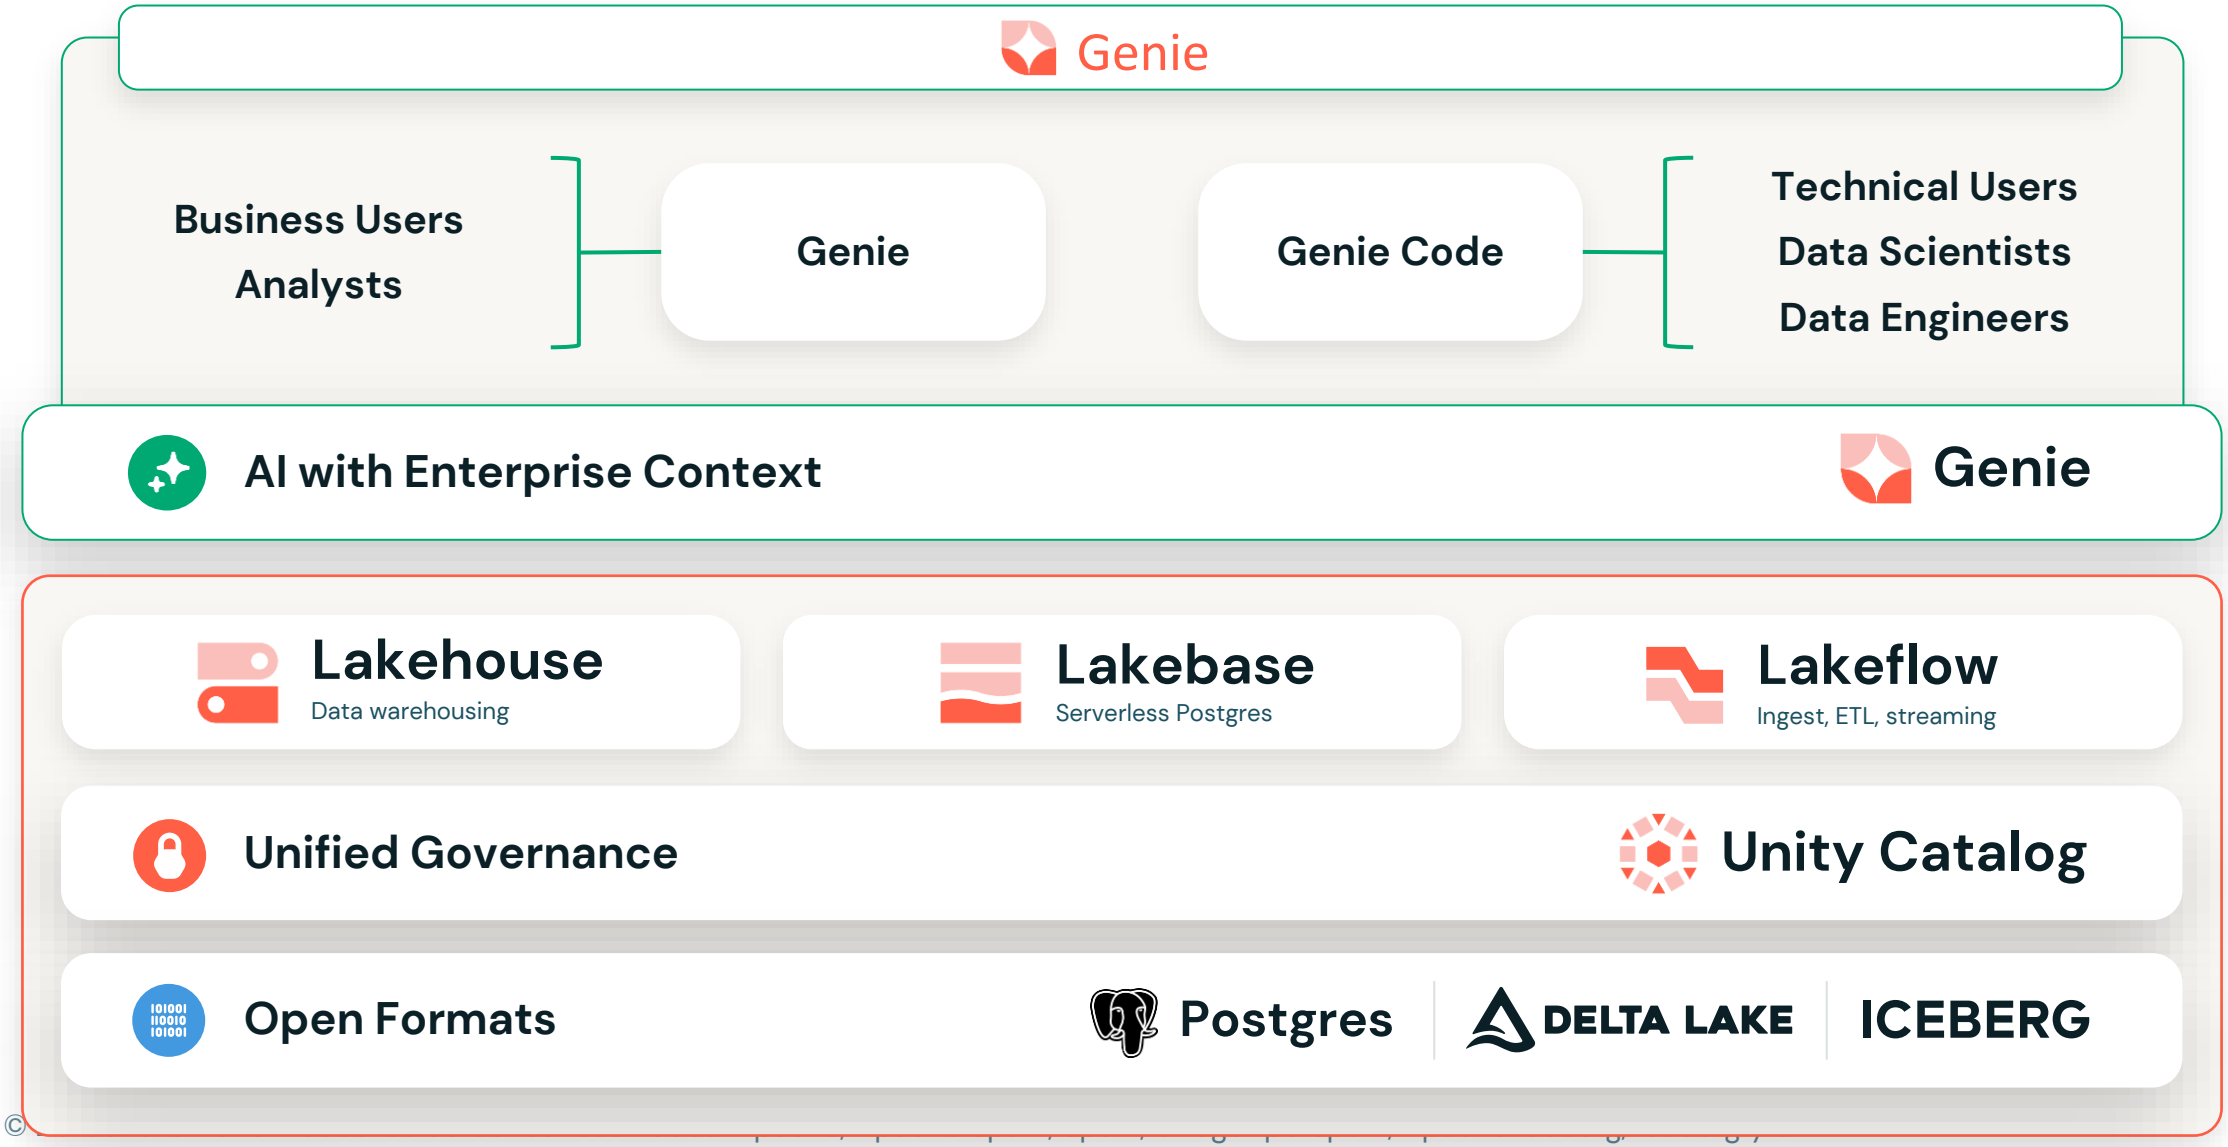
© [illegible] logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

Genie brings new AI capabilities to all roles



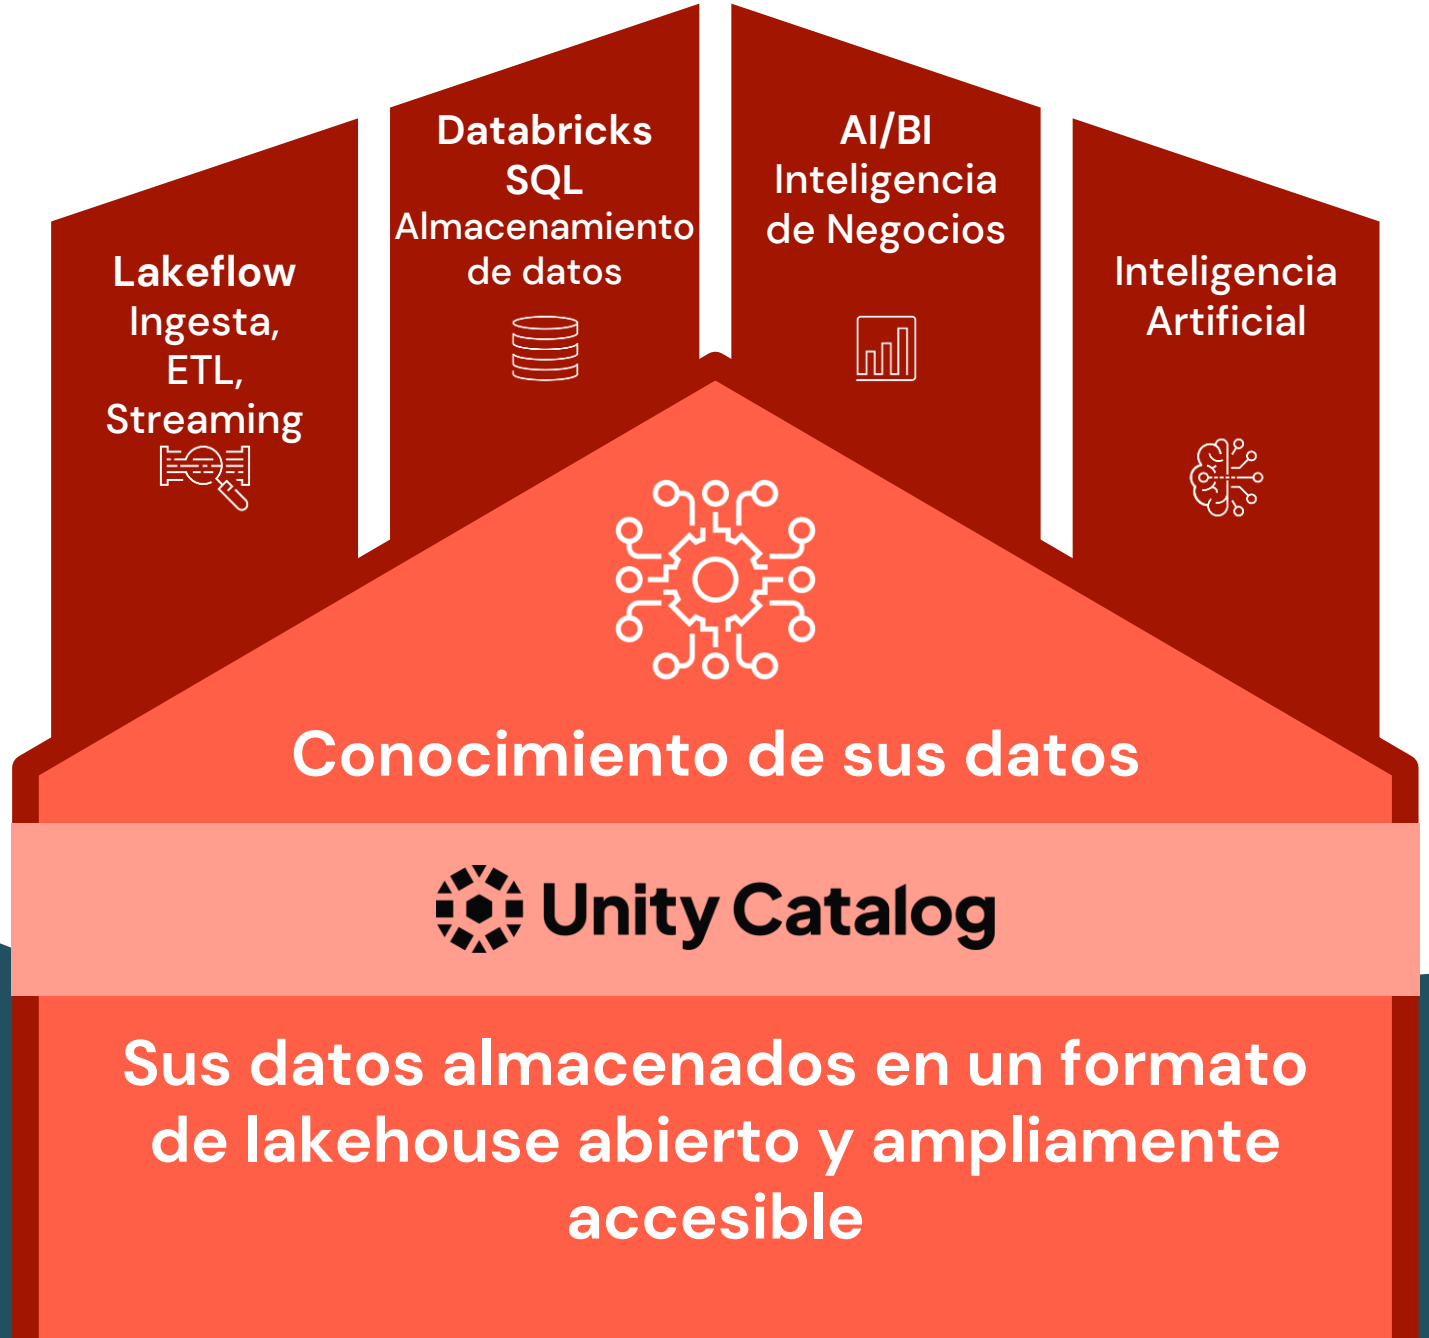
© logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

Genie brings new AI capabilities to all roles

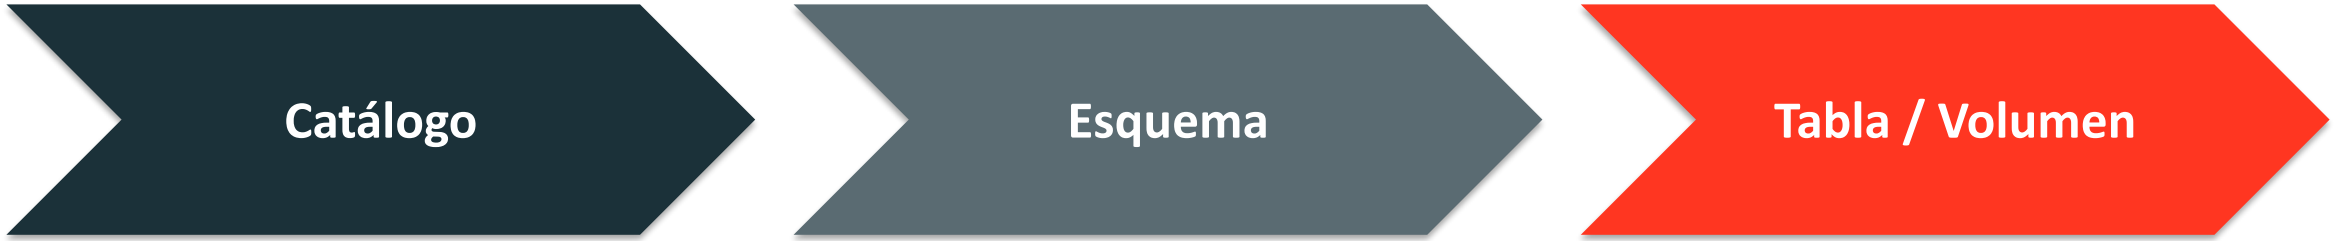


© [illegible] logotipo Apache Iceberg son marcas comerciales de la Apache Software Foundation.

databricks


Lakeflow
Ingesta, ETL, Streaming
Databricks SQL
Almacenamiento de datos
AI/BI
Inteligencia de Negocios
Inteligencia Artificial
Conocimiento de sus datos
Unity Catalog
Sus datos almacenados en un formato de lakehouse abierto y ampliamente accesible

Unity Catalog: cómo se organizan los datos



- Nombres de 3 niveles: catalogo.esquema.objeto
- Volumen = carpeta gobernada para PDFs, CSVs, imágenes
- Tabla Delta = datos estructurados, versionados (time travel)
- Permisos, linaje y búsqueda en un solo lugar

```
CREATE CATALOG IF NOT EXISTS datathon;
CREATE SCHEMA IF NOT EXISTS datathon.gcc;
CREATE VOLUME IF NOT EXISTS datathon.gcc.raw;

-- Ruta del volumen:
-- /Volumes/datathon/gcc/raw/
```

Tip 1: subir los datos a un volumen

- Catalog → catálogo → esquema → volumen
- Botón “Upload to this volume”
- Arrastrar los archivos de la carpeta datos/ del reto
- Para CSV: “Create table” desde la UI o read_files en SQL
- Para PDFs: leerlos como binarios y procesarlos con IA

```
-- CSV a tabla Delta (Bronze)
CREATE OR REPLACE TABLE datathon.roga.bronze_creditos AS
SELECT * FROM read_files(

'/Volumes/datathon/roga/raw/datathon_dataset_entrega.csv',
  format => 'csv', header => true);

-- PDFs como binarios (Emerson)
SELECT path, length
FROM read_files('/Volumes/datathon/emerson/raw/pdfs/',
  format => 'binaryFile');
```

Notebooks y SQL con serverless

- Un notebook mezcla Python, SQL y Markdown
- %sql para cambiar de lenguaje por celda
- spark.table() y spark.sql() conectan Python con tablas
- display() para tablas y gráficas rápidas
- Serverless arranca en segundos; no hay cluster que mantener
- Usen Markdown para documentar decisiones (cuenta en la rúbrica)

```
df = spark.table("datathon.gcc.bronze")
display(df.describe())

# a pandas para ML (datasets chicos)
pdf = df.toPandas()

%sql
SELECT ProductType, avg(Strength28)
FROM datathon.gcc.bronze
GROUP BY ALL
```

Tip 2: Genie Code, tu copiloto

Para qué sirve

- Explorar datos y explicar tablas
- Generar y depurar código Python y SQL
- Diagnosticar errores y proponer correcciones
- Crear dashboards y documentar
- Editar varias celdas o archivos a la vez

Cómo pedirle las cosas

- Sean específicos: tabla, ruta, resultado esperado
- Pidan pasos pequeños y verificables
- Revisen siempre el resultado (ustedes son responsables)
- Ej.: “Lee /Volumes/datathon/gcc/raw/…csv, crea la tabla bronze y muestra nulos por columna”

Arquitectura medallón y Delta Lake

Bronze

- Datos crudos tal cual
- Ingesta trazable

Silver

- Limpieza, tipos, nulos
- Duplicados y outliers

Gold

- Features listas para ML
- Tablas para dashboards

- Delta: transacciones ACID, esquema, historial de versiones (DESCRIBE HISTORY, VERSION AS OF)
- Cada capa es una tabla en Unity Catalog → reproducible y gobernado
- Automatización: notebooks encadenados en un Job (opcional, suma en reproducibilidad)

Machine Learning con MLflow

- Experiment = conjunto de runs comparables
- Run = parámetros + métricas + artefactos (gráficas, modelos)
- mlflow.autolog() registra casi todo automáticamente
- Firma (signature) e input_example al loggear el modelo
- Registrar en Unity Catalog: catalogo.esquema.modelo
- Comparar runs en la UI de Experiments

```
import mlflow
mlflow.set_registry_uri("databricks-uc")
mlflow.autolog()

with mlflow.start_run(run_name="xgb_s28"):
    model.fit(X_train, y_train)
    mlflow.log_metric("mape", mape)
    mlflow.log_param("target", "Strength28")
    mlflow.sklearn.log_model(
        model, "model",
        input_example=X_train[:5],
        registered_model_name=
          "datathon.gcc.strength28")
```

GenAI: de PDFs a búsqueda semántica




```
CREATE OR REPLACE TABLE datathon.emerson.parsed AS
SELECT path,
  ai_parse_document(content) AS parsed
FROM read_files(
  '/Volumes/datathon/emerson/raw/pdfs/',
  format => 'binaryFile');
```

- Chunk por sección del datasheet o por tamaño fijo con traslape
- Guardar part number, fabricante y fuente en cada chunk
- Tabla Delta de chunks → índice de Vector Search (Delta Sync)
- Extraer datos estructurados (precio, stock, status) con ai_query / ai_extract

Agentes: buscar, razonar y recomendar con Genie Agents

- Un agente = LLM + herramientas + instrucciones
- Herramientas típicas:
  - Búsqueda en Vector Search (specs técnicas)
  - Consulta SQL / función UC (precio, stock, status)
- Prompt de sistema con reglas de negocio (solo recomendar ACTIVE, justificar)
- AI Playground para prototipar sin código
- Evaluar con preguntas de prueba y casos borde

Con Genie Agents el proceso se simplifica

- Habilitación rápida de agentes conversacionales
- DEMO

Trabajar con límites: portabilidad entre cuentas

- Git folders: conectar el workspace a GitHub y hacer commit/pull
- Export de notebooks (.ipynb / .dbc / source) e import en otra cuenta
- Scripts idempotentes que recrean catálogo, esquema, volumen y tablas
- Guardar datos crudos en el repo o en el volumen; regenerar Silver/Gold
- Registrar modelos y re-entrenar con un solo notebook

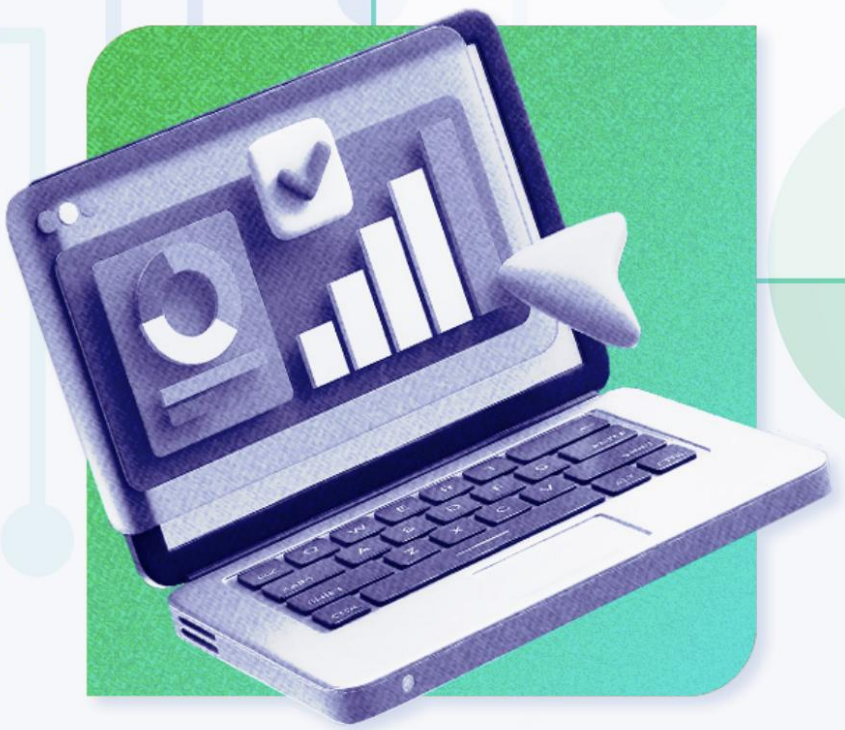
Checklist antes de cambiar de cuenta

- Código en Git actualizado
- Archivos de datos a mano
- Notebook de setup corre de cero
- Nombres de catálogo/esquema parametrizados
- Probar en la cuenta nueva con un subconjunto

Los retos

DATATHON

RETO 1:
Asistente agéntico para reemplazo de hardware especializado



Empresa participante:

EMERSON

MICAI 25 EDITION 2000-2026

02-06 NOV 2026 MEXICAN INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE |ITESM Campus Chihuahua

Reto 1 | Emerson

Asistente agéntico para reemplazo de hardware especializado

Cuando una pieza sale de distribución, recomendar un sustituto activo, compatible y viable (specs, precio, stock). Objetivo financiero: mover un inventario de $4M USD al año.

Datos

- 33 PDFs crudos
- 32 datasheets técnicos
- 1 catálogo comercial (status, precio, stock)
- Sin tablas: ustedes las construyen

Construir

- Parsing + chunking
- Índice vectorial (AI index)
- Agente que recomienda y justifica
- Demo grabada + Excel de TCO

Evaluación

- Problema 10
- Enriquecimiento 15
- Matching 20
- Recomendación 25
- Experiencia 15
- Reproducibilidad 15

Repo

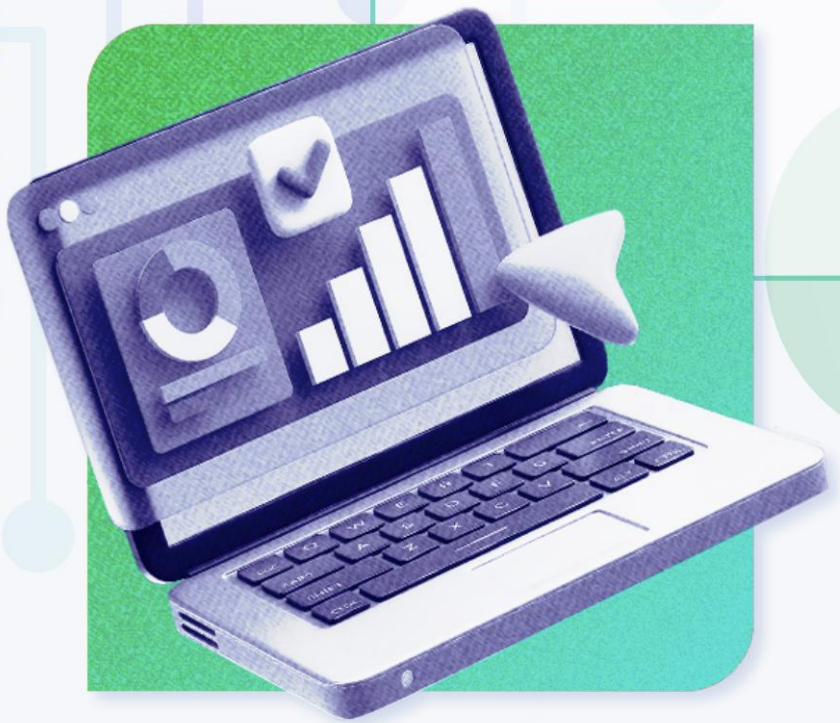
WhatsApp: avisos del reto

50 YEARS: Tecnológico de Monterrey | Campus Chihuahua • Guest Country of Honor: FRANCE | 200 Years of France–Mexico Friendship

DATATHON

RETO 2:

Predicción y aseguramiento de la resistencia mecánica del cemento



Empresa participante:

GCC

MICAI 25 EDITION 2000-2026

02-06 NOV 2026 MEXICAN INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE |ITESM Campus Chihuahua

25TH EDITION OF MICAI: Mexican International Conference on Artificial Intelligence | 02 - 06 November 2026 | Chihuahua, Mexico

Reto 2 | GCC

Predicción de resistencias del cemento (1, 7 y 28 días)

A partir de métricas físicas, fases minerales y composición química, predecir las 3 resistencias y explicar qué variables de calidad las determinan.

Datos

- 1 CSV, 791 registros
- 13 variables de calidad + ProductType
- 3 targets: Strength1/7/28
- Nulos y outliers incluidos

Construir

- Pipeline medallón en UC
- EDA con VIF y correlaciones
- 3 modelos × 3 targets en MLflow
- Dashboard interactivo

Evaluación

- Negocio 15%
- Medallón 20%
- EDA + MLflow 20%
- Modelo 20%
- Dashboard 15%
- Equipo y Q&A 10%
- Escala 1 a 5

Repo

WhatsApp: avisos del reto

50 YEARS: Tecnológico de Monterrey | Campus Chihuahua • Guest Country of Honor: FRANCE | 200 Years of France–Mexico Friendship

DATATHON

RETO 3:

Modelo para la evaluación de solicitudes de crédito



Empresa participante:

GRUPO ROGA

MICAI 25 EDITION 2000-2026

02-06 NOV 2026 MEXICAN INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE |ITESM Campus Chihuahua

25TH EDITION OF MICAI: Mexican International Conference on Artificial Intelligence | 02 - 06 November 2026 | Chihuahua, Mexico

Reto 3 | ROGA

Modelo de otorgamiento de crédito

Predecir al momento de la solicitud si el cliente liquidará su crédito dentro del plazo (cumple_plazo). 34.9% se liquidó fuera de plazo.

Datos

- 1 CSV, 5,935 créditos (2023)
- 20 features de originación
- Diccionario de datos
- Bonus: incobrable (>240 días)

Construir

- EDA y limpieza
- Clasificador con split temporal
- Sin data leakage
- Propuesta de arquitectura

Evaluación

- EDA 30%
- Modelo 40% (AUC > 0.70 = top)
- Arquitectura 30%
- Bonus +10

Repo

WhatsApp: avisos del reto

Checklist de entrega

- Código o notebooks con la solución completa
- Videos para elementos que no llevan código, como el caso de Genie Agents
- README con instrucciones de ejecución
- La solución corre de punta a punta sin intervención
- Entregables específicos de cada reto (ver README):
  - Emerson: Excel de costos y TCO anual
  - GCC: dashboard + experimentos MLflow
  - ROGA: notebook + propuesta de arquitectura
- Todo el equipo debe poder defender la solución
- Cuando estén listos, pidan la habilitación de un folder de entrega al WhatsApp del reto elegido. Se entregará el link a una persona del equipo

Canales y recursos

WhatsApp: mi contacto

Dudas técnicas y de la plataforma

WhatsApp: avisos generales

Anuncios generales, horarios y cambios

¿Preguntas?

¡Éxito a todos los equipos!