DATATHON MICAI 2026

Reto 2 | Predicción de resistencias del cemento

Empresa participante: GCC

Este reto busca predecir las resistencias mecánicas del cemento a partir de variables de calidad del proceso y del producto: métricas físicas, fases minerales y composición química. La solución debe transformar datos crudos en un pipeline reproducible dentro de Databricks, entrenar modelos con seguimiento en MLflow y entregar una experiencia analítica clara para negocio.

---

1. Descripción del problema

En la industria cementera, la calidad del producto y su comportamiento mecánico dependen de múltiples factores físico-químicos. Poder estimar con anticipación la resistencia a 1, 7 y 28 días permite tomar mejores decisiones operativas, reducir merma, optimizar el uso de aditivos y reaccionar más rápido ante desviaciones de calidad.

El reto consiste en construir una solución de datos y machine learning que, a partir de mediciones de calidad del cemento, prediga las resistencias mecánicas esperadas y explique qué variables fueron más relevantes para llegar a cada predicción.

---

2. Datos entregados

Cada equipo recibirá un dataset tabular en CSV con observaciones históricas de calidad y resistencias del cemento, así como la rúbrica oficial de evaluación en Excel.

Recurso	Archivo en este proyecto	Descripción
Dataset principal	`datos/datathon_data_gcc.csv`	Dataset crudo con 791 registros y 16 columnas: variables predictoras de calidad + 3 variables objetivo de resistencia
Rúbrica oficial	`evaluacion/Rubrica_Datathon_GCC.xlsx`	Formato oficial de evaluación con criterios, pesos y escala de calificación

Estructura de la carpeta

```
None
gcc/
├── README.md
├── datos/
│   └── datathon_data_gcc.csv
└── evaluacion/
    └── Rubrica_Datathon_GCC.xlsx
```

Esquema del dataset

Variable categórica

- `ProductType` — tipo de producto

Variables predictoras

- Métricas físicas: `Physical_Metric_A`, `Physical_Metric_B`
- Fases minerales: `Mineral_Phase_A` a `Mineral_Phase_H`
- Composición química: `Chemical_Composition_A`, `Chemical_Composition_B`

Variables objetivo

- `Strength1` — resistencia a 1 día
- `Strength7` — resistencia a 7 días
- `Strength28` — resistencia a 28 días

Observaciones iniciales del dataset

- El archivo trae **791 registros de datos** más el encabezado.
- Hay **5 tipos de producto** visibles: `Type 1`, `Type 2`, `Type 3`, `Type 4` y `Type 5`.
- Existen valores nulos en varias columnas, por lo que el tratamiento de calidad del dato es parte explícita del reto.
- `Strength1`, `Strength7` y `Strength28` son targets y **no deben usarse como features**.

---

3. Qué deben construir

La solución debe incluir, como mínimo, los siguientes componentes:

3.1 Pipeline de limpieza con arquitectura medallón

Construir un pipeline de datos con arquitectura medallón (Bronze → Silver → Gold) en Databricks y Unity Catalog:

Capa	Descripción
Bronze	Datos crudos ingestados desde el CSV tal cual, sin transformaciones
Silver	Datos limpios: manejo de nulos, validación de tipos, eliminación de duplicados, normalización de `ProductType`, codificación de variables categóricas si aplica
Gold	Datos listos para ML: feature engineering, selección de variables predictoras y separación de las 3 resistencias como targets

Criterios de limpieza esperados (Silver):

- Detección y tratamiento de valores nulos
- Detección y tratamiento de outliers
- Verificación de consistencia de tipos
- Eliminación de registros duplicados
- Análisis de multicolinealidad entre variables predictoras

Criterios de preparación esperados (Gold):

- Separación clara entre features (`X`) y targets (`Strength1`, `Strength7`, `Strength28`)
- Escalado o normalización si el modelo lo requiere
- División train/test (recomendado 80/20)

3.2 Análisis exploratorio de datos (EDA)

El EDA debe incluir:

- Estadísticas descriptivas de todas las variables
- Distribuciones de cada variable (histogramas, boxplots)
- Detección de valores nulos y su proporción por columna
- Detección de outliers (método IQR o Z-score)
- Matriz de correlación entre variables predictoras y las 3 resistencias objetivo
- Análisis por `ProductType`
- Scatter plots de las variables más correlacionadas vs cada resistencia
- Análisis de multicolinealidad (VIF) para identificar variables redundantes

3.3 Entrenamiento con MLflow

Entrenar **3 algoritmos diferentes** para predecir **cada una de las 3 resistencias** (`Strength1`, `Strength7`, `Strength28`).

El entrenamiento debe cumplir con:

- Tracking con MLflow para registrar experimentos, métricas, parámetros y artefactos
- Registro de métricas por modelo y target:
  - `R²`
  - `MAE`
  - `MAPE`
  - Gráfico de valores reales vs. predichos
  - Gráfico de residuales
  - Importancia de características, si es posible
- Registro de parámetros mínimos: `model_type`, `target`, `n_features`, `train_size`, `test_size`
- Modelos registrados en MLflow Model Registry
- Tabla comparativa de R^2, MAE y MAPE para los 3 modelos × 3 targets

3.4 Dashboard

Crear un dashboard interactivo que muestre:

- Resumen de resistencias: distribución de `Strength1`, `Strength7` y `Strength28`
- Comparación de modelos: R^2, MAE y MAPE entre los 3 modelos para cada resistencia
- Variables de calidad más importantes para el mejor modelo de cada resistencia
- Relación calidad-resistencia: scatter plots de variables relevantes vs cada resistencia
- Predicciones vs. reales: gráfico de dispersión del mejor modelo para cada resistencia
- Filtro por `ProductType`

El dashboard debe permitir responder:

> "Dado un conjunto de datos de calidad (físicas, mineralogía, química), ¿qué resistencia se obtiene y qué variables de calidad fueron más determinantes para llegar a ese resultado?"

---

4. Arquitectura sugerida del proyecto

```
None
datathon/
├── default/
```

```
|   └── datathon_data_gcc           # Tabla origen (datos crudos)
├── bronze/
|   └── datathon_data_bronze        # Ingesta sin transformaciones
├── silver/
|   └── datathon_data_silver        # Datos limpios y validados
└── gold/
    └── datathon_data_gold          # Features + targets listos para ML
```

Assets sugeridos en Databricks

Asset	Tipo	Descripción
Notebook de ingesta	Notebook	Pipeline Bronze → Silver → Gold
Notebook de EDA	Notebook	Análisis exploratorio completo
Notebook de ML	Notebook	Entrenamiento de 3 modelos × 3 targets con MLflow
Dashboard	AI/BI Dashboard	Visualización de resistencias y variables de calidad
Experimento MLflow	MLflow Experiment	Tracking de métricas y parámetros

---

5. Rúbrica oficial de evaluación

La rúbrica oficial se entrega también en el archivo `evaluacion/Rubrica_Datathon_GCC.xlsx`. La evaluación usa una **escala base de 1.0 a 5.0 puntos** y pondera 6 componentes.

Criterio	Peso	Insuficiente (1)	Aceptable (3)	Excelente (5)
1. Entendimiento del problema y valor de negocio	15%	Ven el proyecto solo como un ejercicio matemático, sin ligarlo a la física o química del cemento	Comprenden la meta de predecir la resistencia, pero no articulan bien el impacto de las variables ni el ahorro real	Vinculan la precisión del modelo con impactos de negocio claros y un modelo financiero sólido
2. Pipeline de limpieza con arquitectura medallón	20%	No hay estructura organizada ni trazabilidad	Hay limpieza básica, pero la separación Bronze/Silver/Gold es difusa o manual	Pipeline automatizado en Unity Catalog con capas claras, reproducibles y gobernadas

Criterio	Peso	Insuficiente (1)	Aceptable (3)	Excelente (5)
3. Análisis EDA y entrenamiento con logging en MLflow	20%	Falta EDA y no hay tracking serio de experimentos	EDA básico y MLflow incompleto	EDA avanzado + registro impecable en MLflow de parámetros, métricas, firmas y ejemplos
4. Modelo multi input / output: calidad → resistencias	20%	El modelo no procesa correctamente las entradas o tiene errores inviables para operar	El modelo funciona, pero queda por debajo del benchmark mínimo en horizontes críticos	El modelo alcanza o supera el benchmark de precisión para R1, R7 y R28
5. Dashboard interactivo	15%	Tablero inexistente, estático o confuso	Dashboard funcional pero rígido	Dashboard interactivo de alta calidad con simulación y alertas visuales dinámicas
6. Participación grupal y sesión de Q&A	10%	El trabajo está centralizado en una sola persona	El equipo expone en conjunto, pero el dominio técnico está concentrado	Todos los integrantes defienden la solución con dominio técnico integral

Cómo se calcula

- Cada criterio se califica en una escala de **1 a 5**.
- El puntaje ponderado se calcula como `peso × calificación`.
- La suma ponderada define la **calificación base obligatoria**, con máximo de **5.0 puntos**.

---

6. Consideraciones importantes

- `Strength1`, `Strength7` y `Strength28` son targets y no deben usarse como features.
- `ProductType` debe tratarse como variable categórica.
- Documenten todas las decisiones de limpieza y feature engineering.
- Garanticen reproducibilidad fijando `random_state` o equivalente en todos los modelos.
- La solución debe correr de punta a punta sin intervención manual del equipo durante la evaluación.

---

7. Nota para todos los retos: tips y restricciones

Tip 1. Suban los datos a un volumen dentro de un esquema y un catálogo

En Databricks, los archivos del reto se gobiernan con Unity Catalog. Recomendamos esta estructura:

1. Crear (o usar) un **catálogo**, por ejemplo `datathon`.
2. Crear un **esquema** para el reto, por ejemplo `datathon.gcc`.
3. Crear un **volumen** dentro del esquema, por ejemplo `datathon.gcc.raw`.
4. Subir `datos/datathon_data_gcc.csv` al volumen desde **Catalog > (catálogo) > (esquema) > (volumen) > Upload to this volume**.
5. Ingerir el CSV desde el volumen para crear las tablas Bronze, Silver y Gold del reto.

Tener los datos en un volumen y en tablas de Unity Catalog facilita su trazabilidad, reutilización y gobierno en notebooks, dashboards, modelos y experimentos.

Tip 2. Usen Genie Code

Genie Code es el asistente de IA integrado en Databricks. Les puede ayudar a:

- Explorar el dataset y entender sus nulos, outliers y correlaciones.
- Generar y depurar código SQL y Python para limpieza, EDA y entrenamiento.
- Diseñar el pipeline medallón y documentar la solución.
- Registrar correctamente experimentos en MLflow.
- Preparar el dashboard y mejorar la reproducibilidad del proyecto.

Sean específicos en sus instrucciones (tablas, rutas del volumen, resultado esperado) y validen siempre el resultado.

Restricción: límites de consumo de Databricks Free Edition

Databricks Free Edition tiene **límites de consumo diario** de cómputo. Esta restricción simula, de forma intencional, el uso de *budgets* y límites de consumo que existen en un entorno empresarial real: diseñen su solución pensando en eficiencia de costos.

Recomendaciones:

- Cada integrante del equipo puede usar su propia cuenta de Databricks Free Edition.
- Si una cuenta alcanza su límite diario, **muevan el código y los objetos** (notebooks, archivos, datos del volumen, tablas, experimentos) a la Free Edition de otro integrante para continuar.
- Mantener el código en un repositorio Git o exportar notebooks facilita este traslado.
- Escriban su solución de forma que se pueda recrear desde cero, lo que además suma puntos en reproducibilidad.

- Prefieran consultas acotadas y eviten dejar recursos encendidos sin uso.

¡Éxito a todos los equipos!